Reinforcement Learning Basic

Week6. Actor Critic

박준영

Hanyang University
Department of Computer Science

지난 시간

- 정책을 근사하는 방법(Policy Gradient)
- REINFORCE 알고리즘

REINFORCE 문제점: Full episode required

$$\mathcal{L} = G_t \log \pi_\theta(a|s)$$

- 손실 함수의 계산에 G_t가 필요하다.
- G_t는 에피소드가 끝나야만 계산할 수 있다.
- 에피소드가 길어지면 G_t의 계산이 무거워진다.

Solution

- 가치 함수를 만들어 G_t 대신 사용한다. ⟵ 오늘의 주제
- 벨만 방정식을 이용해 계산을 중간에 끊는다.

REINFORCE 문제점: High gradient variance

$$\mathcal{L} = G_t \log \pi_\theta(a|s)$$

- G_t의 값은 환경에 따라 매우 천차만별이다.
- G_t의 값이 매우 커지면 gradient가 매우 커진다.
- 학습이 불안정해진다.

Solution

다음과 같이 기준값(baseline)을 손실 함수에 도입한다.

$$\mathcal{L} = (q_\pi(s,a) - b(s))\,\pi_\theta(a|s)$$

Baseline이 될 수 있는 값들:

- 표준화 $\left(Z = \frac{X-\mu}{\sigma}\right)$
- 이동 평균(Moving Mean)
- $V(s) \longleftarrow$ 오늘의 주제

Actor Critic

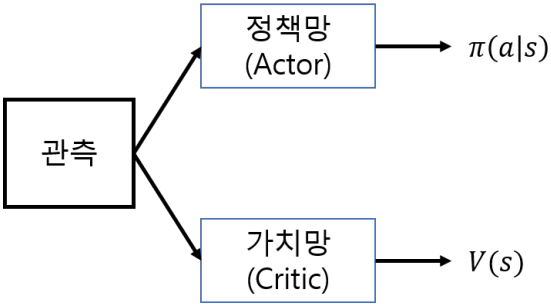

DP 관점에서의 Actor Critic

Actor Critic은 정책 반복의 구조를 사용해 학습한다.

$$\pi_0 \to v_{\pi_0} \to \pi_1 \to v_{\pi_1} \to \pi_2 \to \cdots \to \pi_* \to v_*$$

- 정책 발전 $\longrightarrow$ 정책망의 업데이트.
- 정책 평가 $\longrightarrow$ 가치망을 이용해 정책을 평가.

Actor Critic 알고리즘

1. 인공 신경망을 랜덤하게 초기화한다.
2. 환경과 상호작용 하여 학습 데이터를 만듦.
3. 예상 반환값을 계산.
4. Actor와 Critic의 손실 함수를 계산.
5. SGD로 각 인공 신경망을 갱신함.
6. 수렴할 때까지 2로 돌아감.

Actor Loss Function

REINFORCE 알고리즘에서의 G_t를 큐함수로 대체한다.

$$\mathcal{L} = q_\pi(s, a) \log \pi_\theta(a|s)$$

- 그런데, REINFORCE의 문제점 중 높은 분산은 해결되지 않았다.
  $\longrightarrow$ baseline으로 상태 가치 함수 (s)를 사용한다.

$$\mathcal{L} = (q_\pi(s, a) - v) \log \pi_\theta(a|s)$$

Actor Loss Function

- 하지만 큐함수와 상태 가치 함수를 모두 알고 있어야 하는 번거로움이 있다.
- 큐함수는 상태 가치 함수로 표현할 수 있다.

$$q_\pi(s, a) = R + \gamma v_\pi(s')$$

따라서 최종적인 정책망의 손실 함수는

$$\mathcal{L}_{\text{actor}} = (R + \gamma v(s') - v(s)) \log \pi_\theta(a|s)$$

Critic Loss Function

시간차(TD) 학습을 이용해 가치망을 갱신한다.

$$\mathcal{L}_{\text{critic}} = [R + \gamma v(s') - v(s)]^2$$

구현하기

```python
class ActorNet(nn.Module):
  def __init__(self):
    super(ActorNet, self).__init__()

    self.net = nn.Sequential(
      nn.Linear(4, 64),
      nn.ReLU(inplace=True),
      nn.Linear(64, 2),
      nn.Softmax(dim=0)
    )

  def forward(self, x):
    return self.net(x)
```

구현하기

```
class CriticNet(nn.Module):
  def __init__(self):
    super(CriticNet, self).__init__()

    self.net = nn.Sequential(
      nn.Linear(4, 64),
      nn.ReLU(inplace=True),
      nn.Linear(64, 1)
    )

  def forward(self, x):
    return self.net(x)
```

구현하기

```python
class Agent:
  def __init__(self, device):
    self.device = device

    self.actor = ActorNet().to(device)
    self.actor_opt = optim.Adam(self.actor.parameters(), lr=LEARNING_RATE)

    self.critic = CriticNet().to(device)
    self.critic_opt = optim.Adam(self.critic.parameters(), lr=LEARNING_RATE)
```

구현하기

```python
def get_action(self, state):
  policy = self.actor(state.to(self.device))

  m = Categorical(policy)
  action = m.sample()

  return action.item(), m.log_prob(action)
```

구현하기

```python
def train(self, state, log_prob, next_state, reward, done):
  state, next_state = state.to(self.device), next_state.to(self.device)

  value, next_value = self.critic(state), self.critic(next_state)

  if done:
    target = torch.tensor(reward).to(device)
  else:
    target = reward + DISCOUNT_FACTOR * next_value

  adv = target - value

  self.actor_opt.zero_grad()
  actor_loss = -log_prob * adv.detach()
  actor_loss.backward()
  self.actor_opt.step()

  self.critic_opt.zero_grad()
  critic_loss = (target.detach() - value) ** 2
  critic_loss.backward()
  self.critic_opt.step()
```

구현하기

```python
while True:
  obs = env.reset()
  obs = torch.FloatTensor(obs)

  total_reward = 0

  while True:
    action, log_prob = agent.get_action(obs)
    next_obs, reward, done, _ = env.step(action)

    total_reward += reward

    next_obs = torch.FloatTensor(next_obs)

    agent.train(obs, log_prob, next_obs, reward, done)

    if done:
        break

    obs = next_obs
```